

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Исследовательская часть	3
1.1 Обзор предметной области	3
1.2 Общие определения	4
1.3 Перекрытия	6
1.4 Регулярное представление шаблонов	9
1.4.1 Каскадное произведение автоматов	9
1.4.2 Переход от каскада к ДКА	12
1.5 Распознавание перекрытий с помощью ДКА шаблонов	13
1.6 Иные применения ДКА шаблонов	14
2 Конструкторская часть	16
2.1 Общая архитектура программного комплекса	16
2.2 Архитектура подсистемы семантического анализатора	17
2.2.1 Вспомогательные подмодули семантического анализатора	17
2.2.2 Алгоритм приведения шаблонов функции к ДКА	19
2.3 Алгоритмы извлечения документации к шаблонам функции	19
2.4 Пользовательский интерфейс	19
3 Технологическая часть	19
3.1 Обзор используемых технологий	19
3.2 Реализация модуля для работы с абстрактными паттернами	19
3.3 Реализация модуля для работы с автоматами	19
3.4 Реализация алгоритма обнаружения перекрытий	19
3.5 Реализация алгоритма извлечения документации	19
3.6 Руководство пользователя	19
4 Аналитическая часть	19
ЗАКЛЮЧЕНИЕ	20
СПИСОК ЛИТЕРАТУРЫ	21

АННОТАЦИЯ

ВВЕДЕНИЕ

1 Исследовательская часть

1.1 Обзор предметной области

Язык программирования Рефал имеет довольно большую историю, начавшуюся в 1968 г., когда появилась первая реализация Рефала. Рефал имеет множество диалектов, но все они, по сути, являются надстройками над так называемым базисным Рефалом. Базисный рефал в некотором смысле является самым простым диалектом языка. Программы на базисном Рефале состоят из функций, каждая функция задается парами из шаблона в левой части и выражения в правой.

Единственный тип данных в Рефале — объектное выражение. Это выражение, состоящее из атомарных символов (символ, число) и скобок, при этом скобки правильно вложены. Шаблон в левой части функции — это выражение, в котором, помимо скобок и атомов, могут встречаться переменные. Переменные в шаблоне могут быть трех типов: *e*-переменные, *s*-переменные и *t*-переменные. *e*-переменные могут сопоставляться с любым объектным выражением, *s*-переменные сопоставляются с атомом, *t*-переменные сопоставляются либо с атомом, либо с выражением в скобках. Каждая переменная обладает именем, при этом, если в одном шаблоне есть несколько переменных с одним именем, то при подстановке они заменяются на разные значения.

Основной механизм работы Рефала — сопоставление с образцом и переписывание выражений. При сопоставлении с образцом шаблон в левой части функции сопоставляется с объектным выражением в правой части. Если сопоставление прошло успешно, переменным присваиваются конкретные значения, затем вычисляется выражение в правой части. Сопоставление происходит сверху вниз, если какое-то выражение не сопоставилось ни с одним предложением, это приводит к ошибке времени выполнения.

В листинге 1 функция `IsPal` проверяет, является ли переданное ей выражение, состоящее только из атомов, палиндромом.

Листинг 1 — Пример функции на базисном Рефале

```
1 IsPal {  
2   s.x e.x s.x = <IsPal e.x>;  
3   = True;  
4   s.oneChar = True;  
5   e.otherwise = False;  
6 }
```

Хотя Рефал преимущественно изучается в контексте суперкомпиляции, программы на нём можно исследовать и в контексте статического анализа. Статический анализ программ на Рефале представляет интерес по нескольким причинам. Во-первых, специфика языка — отсутствие явных циклов и присваиваний, опора на сопоставление с образцом и рекурсию — приводит к тому, что многие классические методы анализа, разработанные для императивных языков, неприменимы напрямую и требуют адаптации. Во-вторых, динамическая природа объектных выражений и наличие переменных, способных сопоставляться с выражениями произвольной длины (в первую очередь *e*-переменных), порождает специфические задачи: например, оценку возможных форм результата функции или определение множества выражений, с которыми может быть вызвана та или иная функция.

1.2 Общие определения

Определение 1 (Алфавит). Алфавитом Σ будем называть конечное множество символов.

Будем обозначать алфавиты заглавными греческими буквами.

Определение 2 (Связанные со строками понятия). Строкой $w = w_1w_2 \dots w_n$ будем называть конечную последовательность символов из Σ .

Длиной строки w будем называть число n , обозначаемое как $|w|$.

Пустым словом будем называть строку длины 0, обозначаемую как ε .

i -тый символ строки w будем обозначать как $w[i]$.

Строки будем обозначать строчными латинскими буквами.

Определение 3 (Обращение строки). Для строки $w = w_1w_2 \dots w_n$ будем называть ее обращением строку $w^R = w_n \dots w_2w_1$. Для множества строк $W = \{w_1, w_2, \dots\}$ будем называть его обращением множество $M^R = \{w_1^R, w_2^R, \dots\}$.

Определение 4 (Итерация Клини). Множеством строк Σ^* будем называть множество всех конечных строк над алфавитом Σ . $\varepsilon \in \Sigma^*$. Множество $\Sigma^* \setminus \{\varepsilon\}$ обозначим Σ^+ .

Определение 5 (Сокращенная запись конкатенации). Конкатенацией строк $u = u_1u_2 \dots u_n$ и $v = v_1v_2 \dots v_m$ будем называть строку $u \cdot v = u_1u_2 \dots u_nv_1v_2 \dots v_m$.

Если $M \subset \Sigma^*$ — некоторое множество строк и $w \in \Sigma^*$, то будем обозначать как Mw множество $\{tw \mid t \in M\}$. Аналогично для двух множеств строк M_1, M_2 будем обозначать M_1M_2 множество $\{m_1m_2, m_i \in M_i\}$.

Определение 6. Множество $\Sigma^* \setminus W$ будем обозначать $\overline{W}$ и называть дополнением языка W .

Множества строк будем обозначать заглавными латинскими буквами.

Определение 7 (Строковый морфизм). Строковый морфизм $\phi: \Sigma^* \rightarrow \Gamma^*$ — это функция, которая каждому слову $w \in \Sigma^*$ ставит в соответствие слово $\phi(w) \in \Gamma^*$, сохраняющую конкатенацию, т.е. $\forall w_1, w_2 \in \Sigma^* \phi(w_1w_2) = \phi(w_1)\phi(w_2)$. Строковый морфизм однозначно задается набором значений на символах алфавита Σ . Если для некоторого $\sigma \in \Sigma$ не задано явным образом отображение, будем считать, что σ отображается в себя. В таком случае будем опускать этот факт в записи областей определения и значений морфизма.

Все морфизмы в данной работе — строковые, поэтому будем опускать слово "строковый". Будем обозначать морфизмы строчными греческими буквами.

Пример 1. Пусть $\Sigma = \Gamma = \{a, b, c\}$. Морфизм, меняющий местами a и b , можно задать следующим образом: $\phi: \{a, b\} \rightarrow \{a, b\}$, при этом

$$\begin{aligned}\phi(a) &\mapsto b; \\ \phi(b) &\mapsto a.\end{aligned}$$

В таком способе записи неявно задано $\phi(c) = c$.

Определение 8 (синтаксическая конгруэнция). Синтаксической конгруэнцией языка L будем называть отношение эквивалентности $\sim_L$ такое, что

$$u \sim_L v \iff \forall x, y \in \Sigma^* (xuy \in L \iff xvy \in L)$$

Класс эквивалентности некоторого x в фактор-структуре будем обозначать как $[x]$

Определение 9 (Синтаксический моноид). Фактор-множество $\Sigma^*/\sim_L$ с операцией конкатенации ($[x][y] = [xy]$) — синтаксический моноид языка L .

Определение 10 (синтаксическая полугруппа). Фактор-множество $\Sigma^+/\sim_L$ с операцией конкатенации ($[x][y] = [xy]$) — синтаксическая полугруппа языка L .

Для $n \in \mathbb{N}$ примем $\overline{1, n} = \{1, 2, \dots, n\}$.

1.3 Перекрытия

Определение 11 (Язык правильно вложенных слов). Пусть Σ_{call} , Σ_{ret} и Σ_{int} — непесекающиеся алфавиты. Язык правильно вложенных слов $\mathcal{W}$ — это наименьшее множество, которое генерируется следующими конструкторами:

$$\begin{aligned} \varepsilon &\in \mathcal{W} && \text{(пустое слово)} \\ \gamma &\in \mathcal{W} && \text{для каждого } \gamma \in \Sigma_{\text{int}} \quad \text{(внутренний символ)} \\ w_1 \cdot w_2 &\in \mathcal{W} && \text{если } w_1, w_2 \in \mathcal{W} \\ \langle_c w \rangle_r &\in \mathcal{W} && \text{если } w \in \mathcal{W}, \langle_c \in \Sigma_{\text{call}}, \rangle_r \in \Sigma_{\text{ret}} \end{aligned}$$

Выражением будем называть слова языка правильно вложенных слов $\mathcal{W}_{\text{expr}}$, порожденного алфавитами $\Sigma_{\text{call}} = \{(\}, \Sigma_{\text{ret}} = \{)\}$ и $\Sigma_{\text{int}} = \Delta$, где Δ — счетное множество символов. Абстрактным шаблоном без повторных переменных будем называть слова языка правильно вложенных слов $\mathcal{W}_{\text{pat}}$, порожденного алфавитами $\Sigma_{\text{call}} = \{(\}, \Sigma_{\text{ret}} = \{)\}$ и $\Sigma_{\text{int}} = \{e, s, t\}$.

Замечание 1. Формальное описание абстрактного шаблона без повторных переменных соответствует таким шаблонам языка Рефал, в которых все переменные имеют различные имена и атомарные символы не встречаются вовсе. Например, для диалекта Рефал5- λ , поддерживающего безымянные переменные, из абстрактного шаблона можно получить обычный, заменив все символы e (s, t) абстрактного шаблона на символы e (s , t) шаблона Рефал5- λ .

Введем также понятие шаблона с пронумерованными переменными: каждому шаблону $p \in \mathcal{W}_{\text{pat}}$ поставим в соответствие слово над алфавитом $\Delta_{\mathbb{N}} =$

$\{(\,,\,)\} \cup \{e, s, t\} \times \mathbb{N}$ такое, что все вхождения символов e, s, t в p в шаблоне с пронумерованными переменными заменяются на буквы из $\{e, s, t\} \times \mathbb{N}$, причем i -тому вхождению символа e в p соответствует буква (e, i) (обозначим e_i). Аналогично для s и t . Скобки $(\,,\,)$ остаются на месте. Для шаблона p будем обозначать соответствующий ему шаблон с пронумерованными переменными $p_{\mathbb{N}}$.

Этот формализм нужен лишь затем, чтобы формализовать понятие сопоставления с образцом.

Соответствие переменных множествам их допустимых значений было приведено в обзоре базисного Рефала, теперь же формализуем это соответствие с учетом, что рассматриваются только абстрактные шаблоны без повторных переменных. Будем говорить, что выражение w *допускает сопоставление* с образцом p , если существует строковый морфизм $\phi: \Delta_{\mathbb{N}}^* \rightarrow \mathcal{W}_{\text{expr}}$, действующий следующим образом:

$$\begin{aligned} \phi((s, i)) &\mapsto \gamma \in \Sigma_{\text{int}} \quad \forall i \in \mathbb{N}; \\ \phi((t, i)) &\mapsto \gamma \in \Sigma_{\text{int}} \text{ или } \phi((t, i)) \mapsto (v), \quad v \in \mathcal{W}_{\text{expr}} \quad \forall i \in \mathbb{N}, \end{aligned}$$

при этом $\phi(p_{\mathbb{N}}) = w$.

Определение 12 (Язык шаблона). Языком шаблона $p \in \mathcal{W}_{\text{pat}}$ будем называть множество всех выражений $w \in \mathcal{W}_{\text{expr}}$, которые допускают сопоставление с p . Обозначать это множество будем как $\mathcal{L}(p)$.

Каждая функция Рефала задается последовательностью предложений, каждое из которых в свою очередь содержит шаблон в левой части. Для некоторой функции f , содержащей n предложений, будем обозначать i -тый по счету (считая сверху вниз) шаблон предложения как $f.p_i$. Последовательность всех шаблонов функции $\langle f.p_1, f.p_2, \dots, f.p_n \rangle$ будем обозначать как **pat** f .

Определение 13 (Перекрытие). Будем говорить, что шаблон p *перекрывается* или *экранируется* шаблонами $p_1, p_2, \dots, p_k$, если

$$\mathcal{L}(p) \subseteq \bigcup_{i=1}^k \mathcal{L}(p_i).$$

Будем говорить, что перекрытие (экранирование) *множественное*, если $k > 1$.

Итак, после введения всех необходимых понятий, мы можем перейти к определению задачи распознавания перекрытия:

Определение 14 (Задача распознавания перекрытия). Задача распознавания перекрытия в функции f с n предложениями заключается в том, чтобы для каждого шаблона $p_i \in \mathbf{pat} f$, $i \in \overline{1, n}$ найти минимальное по включению множество $I = \{i_1, i_2, \dots, i_k\} \subseteq \overline{1, i-1}$ такое, что p_i перекрывается шаблонами $f.p_{i_1}, f.p_{i_2}, \dots, f.p_{i_k}$, или показать, что такого множества не существует.

Отметим, что решение задачи распознавания перекрытия неоднозначно, так как для одного и того же шаблона можно найти несколько минимальных по включению множеств индексов таких, что соответствующие им шаблоны перекрывают искомый. Пример такого случая приведён в листинге 2. Предложение 5 перекрывается предложениями 3 и 4, а также предложением 1. При этом множества $\{3, 4\}$ и $\{1\}$ несравнимы по включению.

Листинг 2 — Пример неоднозначного экранирования предложений Рефал-функции

```

1 F {
2     (t._ t._) e._ = ...;           /* 1 */
3     e._ (s._ e._ s._) e._ = ...;   /* 2 */
4     e._ s._ (t._) = ...;           /* 3 */
5     e._ (e._) (t._) = ...;         /* 4 */
6     (t._ t._) t._ (t._) = ...;     /* 5 */
7 }
```

Забегая вперед, отметим, что в текущей постановке задача распознавания перекрытия алгоритмически труднее, чем ее упрощенный вариант:

Определение 15 (Упрощенная задача распознавания перекрытия). Упрощенная задача распознавания перекрытия в функции f заключается в том, чтобы для каждого шаблона $p_i \in \mathbf{pat} f$ определить, экранируется ли он шаблонами $p_1, p_2, \dots, p_{i-1}$.

Искомое определение задачи распознавания перекрытия будем называть теперь полным или точным.

1.4 Регулярное представление шаблонов

Регулярное представление шаблона представляет особый интерес, поскольку, в сравнении с контекстно-свободными языками (в частности, языками с магазинным автоматов, управляемых входом), коими являются $\mathcal{W}_{\text{expr}}$ и $\mathcal{W}_{\text{pat}}$, регулярные языки более просты для анализа.

1.4.1 Каскадное произведение автоматов

Рассмотрим основную теоретическую конструкцию, позволяющую извлекать регулярное представление шаблонов — каскадное произведение автоматов:

Определение 16 (Каскадное произведение автоматов). Пусть $A_1 = \langle Q_1, \Sigma, \delta_1, q_{0_1}, F_1 \rangle$ и $A_2 = \langle Q_2, \Sigma \times Q_1, \delta_2, q_{0_2}, F_2 \rangle$ — детерминированные конечные автоматы. Каскадным произведением $A_1 \circ A_2$ называется ДКА $\langle Q, \Sigma, \delta, q_0, F \rangle$, где

$$\begin{aligned} Q &= Q_1 \times Q_2, \\ q_0 &= (q_{0_1}, q_{0_2}), \\ F &= F_1 \times F_2, \\ \delta((q_1, q_2), a) &= (\delta_1(q_1, a), \delta_2(q_2, (a, q_1))). \end{aligned}$$

Иногда будем просто говорить о каскаде (двух и более автоматов), подразумевая каскадное произведение автоматов.

Определение, данное выше, является вариантом прямого произведения автоматов. Как и многие другие операции над ДКА, использующие прямое произведение (например, пересечение и объединение), каскадное произведение можно описать как систему из двух автоматов, работающих параллельно на одном и том же входном слове. В случае каскада двух автоматов между ними проявляется односторонняя зависимость: оба автомата синхронно читают посимвольно входное слово $w \in \Sigma^*$, при этом первый автомат A работает автономно над алфавитом Σ , а второй автомат, помимо символа $w[i]$, использует текущее (до перехода по $w[i]$) состояние первого автомата q , т.е. работает над алфавитом $\Sigma \times Q_1$.

Основная идея заключается в делегировании распознавания вложенных подшаблонов элементам каскада.

Введем искомый алфавит $\Gamma_0 = \{b, s, (,)\}$. b является мета-символом, соответствующим словам $\mathcal{W}_{\text{expr}} \ni w = (v)$, $v \in \mathcal{W}_{\text{expr}}$, s также является мета-символом, соответствующим словам $\mathcal{W}_{\text{expr}} \ni w = \gamma \in \Sigma_{\text{int}}$. Будем рассматривать регулярные выражения r над алфавитом Γ_0 и ДКА A над этим же алфавитом. Будем обозначать множество слов $\{w \mid w \in \Gamma_0^*\}$, принадлежащие языку $r(A)$, как $R(r)$ ($R(A)$). Отклонение от стандартного обозначения через $\mathcal{L}$ сделано во избежание путаницы: каждое слово языка $r(A)$ в силу смысла символов $\gamma \in \Gamma_0$ само задает некоторый язык слов-выражений из $\mathcal{W}_{\text{expr}}$. Для слова $u \in R(r)$ поставим ему в соответствие слово $u_{\mathbb{N}}$ над $\Gamma_{\mathbb{N}} = \{(,)\} \cup \{b, s\} \times \mathbb{N}$ с пронумерованными переменными, аналогично тому, как это было сделано для шаблонов $p \in \mathcal{W}_{\text{pat}}$ и $p_{\mathbb{N}}$. Будем говорить, что w допускает сопоставление с r , если

$$\exists u \in R(r) \exists \phi: \{b, s\} \times \mathbb{N} \rightarrow \mathcal{W}_{\text{expr}} \mid \phi(u_{\mathbb{N}}) = w,$$

при этом

$$\begin{aligned} \phi((b, i)) &\mapsto (w) \in \mathcal{W}_{\text{expr}} \forall i \in \mathbb{N}; \\ \phi((s, i)) &\mapsto \gamma \in \Sigma_{\text{int}} \forall i \in \mathbb{N}; \end{aligned}$$

Множество слов $w \in \mathcal{W}_{\text{expr}}$, допускающих сопоставление с r , будем обозначать как $\mathcal{L}(r)$. Любой шаблон $p \in \mathcal{W}_{\text{pat}}$ можно представить в виде регулярного выражения r над алфавитом Γ так, что $\mathcal{L}(p) = \mathcal{L}(r)$. Данный факт следует непосредственно из определения самих e, t, s -символов, ниже представлено соответствие между символами и регулярными выражениями:

- e -символ соответствует выражению $(b|s)^*$;
- t -символ соответствует выражению $(b|s)$;
- s -символ соответствует выражению s .

Введем функцию глубины вложенности на элементах языка правильно вложенных слов:

$$d(w, i) = \begin{cases} 0, & i = 0 \\ d(w, i - 1) + 1, & w[i] \in \Sigma_{\text{call}} \\ d(w, i - 1) - 1, & w[i] \in \Sigma_{\text{ret}} \\ d(w, i - 1), & w[i] \in \Sigma_{\text{int}} \end{cases}$$

Тогда максимальным уровнем вложенности некоторого слова w будет

$$\max d(w) = \max_{i \in \overline{1, |w|}} d(w[i]).$$

Подшаблоном p уровня вложенности k (или просто k -подшаблоном) будем называть подслово $w[i : j]$ такое, что

$$d(w, i) = k \wedge d(w, j) = k - 1 \wedge \forall m \in \overline{i + 1, j - 1} \ d(w, m) \geq k - 1.$$

Обозначим множество всех k -подшаблонов p как **subpat** _{k} (p).

Рассмотрим теперь теоретическую конструкцию каскада по данному шаблону p . Сначала для $k = \max(p)$ построим регулярные выражения r_i над алфавитом Γ_0 по правилам, описанным выше, для всех k -подшаблонов p_i ; далее построим соответствующие ДКА A_i .

Рассмотрим ДКА-объединение A всех A_i с размеченными состояниями: каждое финальное состояние f автомата A помечается множеством $\alpha \subset \mathbf{subpat}_k(p)$, если все пути в автомате A до состояния f принадлежат языкам регулярных выражений, соответствующим k -подшаблонам $p_j \in \alpha$. Чтобы автомат корректно работал только с k -шаблонами, автомат A совмещается с автоматом-лифтом на уровень скобочной вложенности k . Начальным состоянием A становится начальное состояние лифта, последний этаж лифта совмещается с бывшим начальным состоянием A . Пример автомата-лифта для уровня 2 приведен на рисунке РИС!.

Полученный автомат A является управляющим автоматом каскада. Если $k > 1$, то следующий элемент каскада будет управляться символом входного слова и состоянием A . Для построения управляемого автомата B необходимо рассмотреть множество **subpat** _{$k-1$} , его элементы включают себя k -шаблоны в качестве подшаблонов. Для принятия решения о переходе по этим k -шаблонам автомат B использует состояния автомата A , аннотации финальных состояний A позволяют автомату B получать необходимую информацию о том, какие шаблоны прочитаны A .

Итак, конструкция выше задает пару автоматов, каскадное произведение которых $A \circ B$ распознает $k - 1$ -шаблоны. Повторяя процедуру выше для $k, k -$

$1, \dots, 0$ -шаблонов, получаем каскад $A_k \circ A_{k-1} \circ \dots \circ A_0$, распознающий искомый шаблон.

Рассмотрим пример функции, приведённой в листинге 3.

Листинг 3 — Пример функции на базисном Рефале

```

1 f {
2   t.first (e.x (s.y) s.z) = ...;
3   ((t.x) e.y s.z) s.last = ...;
4 }
```

Для примера в листинге 3 шаблонами уровня вложенности 2 будут s, t ; уровня 1 — $e(s)s, (t)es$; без скобочной вложенности — $t(e(s)s), ((t)es)s$.

1.4.2 Переход от каскада к ДКА

Конструкция выше является теоретическим обоснованием подхода, описанного ниже. Покажем, что от явного построения каскада можно избавиться вовсе и обойтись лишь построением аннотированного ДКА-объединения для подшаблонов всех уровней вложенности.

Рассмотрим структуру любого управляемого элемента каскада. В любом состоянии после перехода по открывающей скобке управляемый автомат "ожидает" закрывающую скобку нужного уровня, фактически игнорируя все символы, поступающие на вход до нее. Этот факт потребуется в дальнейшем.

Введем на множестве состояний Q аннотированного автомата отношение эквивалентности $\sim_\alpha$, для $q_1, q_2 \in Q$ имеем $q_1 \sim_\alpha q_2$ тогда, и только тогда, когда аннотация q_1 совпадает с q_2 . Будем называть элементы этого фактора $b_0, b_1, \dots, b_n$.

Заметим, что все состояния элемента каскада с одинаковыми аннотациями неразличимы с точки зрения элемента младшего уровня, а также то, что состояния с уникальной аннотацией дизъюнкты относительно других языков путей к другим аннотациям. Выразаясь немного неформально, язык b_i не пересекается с языками $b_j, j \neq i$.

Воспользовавшись наблюдениями выше, можно свести каскад к построению отдельных ДКА в различных алфавитах по следующим правилам:

1. Первый управляющий автомат $A_k = \langle Q, q_0, F, \delta \rangle$ над $\{s, b\}$ строится как и ранее.

2. Строится фактор-множество $Q / \sim_\alpha$, при этом к нему добавляется элемент $\emptyset$, если в A_k есть хоть одно непринимаящее полезное состояние.
3. Младший элемент каскада строится над алфавитом $s, b_0, b_1, \dots, b_n$ следующим образом — по шаблону все так же можно построить регулярное выражение, но символ b теперь заменяется набором $b_0, b_1, \dots, b_n$. По регулярному выражению построить ДКА.
4. Если еще не построен ДКА для 0-шаблонов, перейти к шагу 2, иначе завершить построение.

Таким образом, в данной конструкции бремя различия несовпадающих вложенных подшаблонов ложится на алфавит. Конечным результатом алгоритма, следующего правилам выше, будет ДКА искомого шаблона в некотором алфавите $s, b_0, b_1, \dots, b_n$.

Заметим, что по построению общее число аннотаций на каждого уровне относительно числа k -шаблонов n есть $O(2^n)$. Именно этим обусловлен отказ от рассмотрения шаблонов, содержащих атомарные символы — в шаблонах с высоким уровнем вложенности различие констант может привести к очень сильному разрастанию алфавита.

1.5 Распознавание перекрытий с помощью ДКА шаблонов

При решении задачи экранирования необходимо различать множество $\bigcup_i \text{subpat}_k(p_i)$ всех k -подшаблонов всех шаблонов некоторой функции f . Конструкция выше тривиально обобщается на несколько паттернов: для всех k вместо $\text{subpat}_k(p)$ конкретного паттерна рассматривается объединенное множество $\bigcup_i \text{subpat}_k(p_i)$.

Для набора паттернов P и паттерна s можно определить, экранируется ли паттерн s множеством паттернов P , построив для каждого $p \in P$ и для s ДКА. Обозначим эти ДКА $A_1, A_2, \dots, A_n$ и A_s соответственно. Тогда шаблоны из P экранируют s , если

$$\mathcal{L}(A_s) \subset \bigcup_i \mathcal{L}(A_i)$$

Операции над языками автоматов можно свести к операциям над автоматами с помощью известных операций пересечения, объединения и дополнения.

1.6 Иные применения ДКА шаблонов

Не всегда язык паттерна $\mathcal{L}(p)$ совпадает с множеством слов, которые могут сопоставиться с этим паттерном, находящимся где-то в теле функции. Как правило, языки паттернов в функции не являются дизъюнктными, а значит часть $\mathcal{L}(p)$ может буквально не доходить до паттерна p , обрабатываясь предложениями выше. Для $f.p_i$ будем называть его фактическим языком множество

$$\mathcal{L}(f.p_i) \cap \overline{\bigcup_{j \in \overline{1, i-1}} \mathcal{L}(f.p_j)}.$$

Рассмотрим пример гипотетической функции, приведённой в листинге 4.

Листинг 4 — Некоторая функция, обрабатывающая какие-то данные (в диалекте Рефал5-λ)

```

1 AnalyzeData {
2   t.node /* empty */ = <AnalyzeData <AppendData t.node>>;
3   t.node t.data, t.data : {
4     ...
5   };
6   e.otherwise = <Error>;
7 }
```

В данном примере очевидно, что паттерн третьего предложения *AnalyzeData.p₃* можно уточнить:

$$e.otherwise \xrightarrow{\sim} t.1 \ t.2 \ t.3 \ e.4$$

Менее очевидный пример представлен в листинге 5. Для последнего паттерна можно вывести, что все слова, сопоставляющиеся с этим паттерном, или начинаются с пустых скобок $()$, либо с непустых скобок, содержимое которых начинается с непустой скобки (иными словами — $((t.1e.2)e.3)$).

Листинг 5 — Функция h

```
1 h {  
2   () t.1 = ...;  
3   (e.1 () e.3) e.4 = ...;  
4   (s.1 e.1) e.2 = ...;  
5   (e.1) e.2 s.1 e.3 = ...;  
6   (e.1) e.2 = ...;  
7 }
```

Множеством обязательных префиксов языка W называется множество U такое, что $\forall w \in W \exists u \in U \exists v \in \Sigma^* (w = uv)$. Обходя в ширину ДКА фактического языка 0-шаблонов можно строить дерево обязательных префиксов. Помимо этого, можно извлекать обязательные инфиксы. Это простое наблюдение нуждается в аккуратной реализации: в самом наглядном представлении обязательных префиксов — перечислении — может оказаться слишком много элементов.

2 Конструкторская часть

2.1 Общая архитектура программного комплекса

Было решено работать с диалектом Рефал5-λ, поскольку этот диалект, во-первых, является точным надмножеством Рефала-5, а во-вторых является современной реализацией Рефала, знакомой автору.

Рационально поделить программный комплекс на две части — библиотеку, содержащую всю логику работы с шаблонами, автоматами, алгоритмами и т.п., и приложение с интерфейсом командной строки, использующую эту библиотеку.

Устройство самой библиотеки следует классической архитектуре большинства фронтендов компиляторов. Таким образом, библиотека делится на три модуля:

- модуль `lexer` — модуль, отвечающий за лексический анализ;
- модуль `parser` — модуль, отвечающий за синтаксический анализ;
- модуль `sema` — модуль, отвечающий за семантический анализ.

Модуль `sema` единственный предоставляет публичные функции, доступные для вызова извне. Сами модули взаимодействуют друг с другом весьма ограничено, сохраняя свою внутреннюю логику закрытой. Схема взаимодействия модулей представлена на рисунке РИС!.

Лексический и синтаксический анализаторы не представляют особого интереса — Рефал5-λ имеет сравнительно простую лексическую структуру, а грамматика языка ССЫЛКА! допускает реализацию синтаксического анализа рекурсивным спуском. Так как основная цель работы — написание семантического анализатора, лексический и синтаксический анализаторы реализованы довольно просто, и не имеют продвинутых способов восстановления после ошибок.

2.2 Архитектура подсистемы семантического анализатора

2.2.1 Вспомогательные подмодули семантического анализатора

Семантический анализатор, будучи самым крупным модулем библиотеки, содержит в себе несколько подмодулей, выполняющих различные задачи.

Первым таким подмодулем является модуль `automata`, отвечающий за работу с автоматами и за способ хранения ДКА и НКА в памяти. При разработке прототипа приложения и его тестировании было установлено, что в абсолютном большинстве случаев автоматы имеют размер до десяти тысяч состояний, а размер алфавита не превышает одной тысячи. В связи с этим в итоге было выбрано сжатое разрежённое строковое представление для исходящих и входящих ребер. Пример такого представления приведен на рисунке РИС!. Остслеживать входящие ребра легко при построении ДКА, в дальнейшем это дает выигрыш при реализации алгоритмов минимизации и удаления бесполезных состояний. В числе операций на ДКА, реализованных в модуле, присутствуют:

- объединение;
- аннотированное объединение;
- пересечение;
- конкатенация (через прямое произведение);
- конкатенация (через построение НКА);
- дополнение;
- проверка языков автоматов на включение;
- минимизация;
- удаление бесполезных состояний.

Необходимость двух вариантов конкатенации ДКА будет обусловлена в следующем разделе. НКА в модуле нужны лишь для того, чтобы стать результатом конкатенации ДКА и сразу же быть детерминизированными.

Второй подмодуль `abstract_patterns` позволяет из конкретных АСТ-узлов строить абстрактные шаблоны, эквивалентные шаблонам из $\mathcal{W}_{\text{pat}}$. Наличие такого модуля значительно облегчает дальнейшую обработку шаблонов. Ключевой функцией в модуле является функция получения из АСТ-узла определения

функции набора абстрактных шаблонов и сопутствующей информации; наличие этой информации обусловлено необходимостью различать шаблоны, изначально удовлетворяющие определению шаблонов из $\mathcal{W}_{\text{pat}}$, от остальных. Модуль в том числе несет ответственность за преобразование всех шаблонов к виду, описанному в исследовательской части. Информация об абстрактном шаблоне включает в себя следующие факты:

- были ли в искомом шаблоне повторные переменные;
- были ли в искомом шаблоне атомарные символы;
- были ли в предложении функции, соответствующем искомому шаблону, условия.

2.2.2 Алгоритм приведения шаблонов функции к ДКА

2.3 Алгоритмы извлечения документации к шаблонам функции

2.4 Пользовательский интерфейс

3 Технологическая часть

3.1 Обзор используемых технологий

3.2 Реализация модуля для работы с абстрактными паттернами

3.3 Реализация модуля для работы с автоматами

3.4 Реализация алгоритма обнаружения перекрытий

3.5 Реализация алгоритма извлечения документации

3.6 Руководство пользователя

4 Аналитическая часть

ЗАКЛЮЧЕНИЕ

СПИСОК ЛИТЕРАТУРЫ