

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Исследовательская часть	3
1.1 Обзор предметной области	3
1.2 Общие определения	4
1.3 Перекрытия	6
1.4 Регулярное представления шаблонов	9
1.4.1 Каскадное произведение автоматов	9
1.4.2 Переход от каскада к ДКА	13
1.5 Распознавания перекрытий с помощью ДКА шаблонов	13
1.6 Иные применения ДКА шаблонов	13
2 Конструкторская часть	13
2.1 Общая архитектура программного комплекса	13
2.1.1 Обработка ошибок	13
2.2 Архитектура подсистемы семантического анализатора	13
2.2.1 Вспомогательные подмодули семантического анализатора	13
2.2.2 Алгоритм приведения шаблонов функции к ДКА	13
2.3 Алгоритмы извлечения документации к шаблонам функции	13
2.4 Пользовательский интерфейс	13
3 Технологическая часть	13
3.1 Обзор используемых технологий	13
3.2 Реализация модуля для работы с абстрактными паттернами	13
3.3 Реализация модуля для работы с автоматами	13
3.4 Реализация алгоритма обнаружения перекрытий	13
3.5 Реализация алгоритма извлечения документации	13
3.6 Руководство пользователя	13
4 Аналитическая часть	13
ЗАКЛЮЧЕНИЕ	14
СПИСОК ЛИТЕРАТУРЫ	15

АННОТАЦИЯ

ВВЕДЕНИЕ

1 Исследовательская часть

1.1 Обзор предметной области

Язык программирования Рефал имеет довольно большую историю, начавшуюся в 1968 г., когда появилась первая реализация Рефала. Рефал имеет множество диалектов, но все они, по сути, являются надстройками над так называемым базисным Рефалом. Базисный рефал в некотором смысле является самым простым диалектом языка. Программы на базисном Рефале состоят из функций, каждая функция задается парами из шаблона в левой части и выражения в правой.

Единственный тип данных в Рефале — объектное выражение. Это выражение, состоящее из атомарных символов (символ, число) и скобок, при этом скобки правильно вложены. Шаблон в левой части функции — это выражение, в котором, помимо скобок и атомов, могут встречаться переменные. Переменные в шаблоне могут быть трех типов: *e*-переменные, *s*-переменные и *t*-переменные. *e*-переменные могут сопоставляться с любым объектным выражением, *s*-переменные сопоставляются с атомом, *t*-переменные сопоставляются либо с атомом, либо с выражением в скобках. Каждая переменная обладает именем, при этом, если в одном шаблоне есть несколько переменных с одним именем, то при подстановке они заменяются на разные значения.

Основной механизм работы Рефала — сопоставление с образцом и переписывание выражений. При сопоставлении с образцом, шаблон в левой части функции сопоставляется с объектным выражением в правой части. Если сопоставление прошло успешно, переменным присваиваются конкретные значения, затем вычисляется выражение в правой части. Сопоставление происходит сверху вниз, если какое-то выражение не сопоставилось ни с одним предложением, это приводит к ошибке времени выполнения.

В листинге 1 функция `IsPal` проверяет, является ли переданное ей выражение, состоящее только из атомов, палиндромом.

Листинг 1 — Пример функции на базисном Рефале

```
1 IsPal {  
2   s.x e.x s.x = <IsPal e.x>;  
3   = True;  
4   s.oneChar = True;  
5   e.otherwise = False;  
6 }
```

Будучи преимущественно объектом исследования в области суперкомпиляции, Рефал-программы можно исследовать и в контексте статического анализа. Статический анализ программ на Рефале представляет интерес по нескольким причинам. Во-первых, специфика языка — отсутствие явных циклов и присваиваний, опора на сопоставление с образцом и рекурсию — приводит к тому, что многие классические методы анализа, разработанные для императивных языков, неприменимы напрямую и требуют адаптации. Во-вторых, динамическая природа объектных выражений и наличие переменных, способных сопоставляться с выражениями произвольной длины (в первую очередь *e*-переменных), порождает специфические задачи: например, оценку возможных форм результата функции или определение множества выражений, с которыми может быть вызвана та или иная функция.

1.2 Общие определения

Определение 1 (Алфавит). Алфавитом Σ будем называть конечное множество символов.

Будем обозначать алфавиты заглавными греческими буквами.

Определение 2 (Связанные со строками понятия). Строкой $w = w_1w_2 \dots w_n$ будем называть конечную последовательность символов из Σ .

Длиной строки w будем называть число n , обозначаемое как $|w|$.

Пустым словом будем называть строку длины 0, обозначаемую как ε .

i -тый символ строки w будем обозначать как $w[i]$.

Строки будем обозначать строчными латинскими буквами.

Определение 3 (Обращение строки). Для строки $w = w_1w_2 \dots w_n$ будем называть ее обращением строку $w^R = w_n \dots w_2w_1$. Для множества строк $W = \{w_1, w_2, \dots\}$ будем называть его обращением множество $M^R = \{w_n^R, w_2^R, \dots\}$.

Определение 4 (Итерация Клини). Множеством строк Σ^* будем называть множество всех конечных строк над алфавитом Σ . $\varepsilon \in \Sigma^*$. Множество $\Sigma^* \setminus \{\varepsilon\}$ обозначим Σ^+ .

Определение 5 (Сокращенная запись конкатенации). Конкатенацией строк $u = u_1u_2 \dots u_n$ и $v = v_1v_2 \dots v_m$ будем называть строку $u \cdot v = u_1u_2 \dots u_nv_1v_2 \dots v_m$.

Если $M \subset \Sigma^*$ — некоторое множество строк и $w \in \Sigma^*$, то будем обозначать как Mw множество $\{mw \mid m \in M\}$. Аналогично для двух множеств строк M_1, M_2 будем обозначать M_1M_2 множество $\{m_1m_2, m_i \in M_i\}$.

Определение 6. Множество $\Sigma^* \setminus W$ будем обозначать $\overline{W}$ и называть дополнением языка W .

Множества строк будем обозначать заглавными латинскими буквами.

Определение 7 (Строковый морфизм). Строковый морфизм $\phi: \Sigma^* \rightarrow \Gamma^*$ — это функция, которая каждому слову $w \in \Sigma^*$ ставит в соответствие слово $\phi(w) \in \Gamma^*$, сохраняющая конкатенацию, т.е. $\forall w_1, w_2 \in \Sigma^* \phi(w_1w_2) = \phi(w_1)\phi(w_2)$. Строковый морфизм однозначно задается набором значений на символах алфавита Σ . Если для некоторого $\sigma \in \Sigma$ не задано явным образом отображение, будем считать, что σ отображается в себя. В таком случае будем опускать этот факт в записи областей определения и значений морфизма.

Все морфизмы в данной работе — строковые, поэтому будем опускать слово "строковый". Будем обозначать морфизмы строчными греческими буквами.

Пример 1. Пусть $\Sigma = \Gamma = \{a, b, c\}$. Морфизм, меняющий местами a и b , можно задать следующим образом: $\phi: \{a, b\} \rightarrow \{a, b\}$, при этом

$$\phi(a) \mapsto b;$$

$$\phi(b) \mapsto a.$$

В таком способе записи неявно задано $\phi(c) = c$.

Определение 8 (синтаксическая конгруэнция). Синтаксической конгруэнцией языка L будем называть отношение эквивалентности $\sim_L$ такое, что

$$u \sim_L v \iff \forall x, y \in \Sigma^* (xuy \in L \iff xvy \in L)$$

Класс эквивалентности некоторого x в фактор-структуре будем обозначать, как $[x]$

Определение 9 (Синтаксический моноид). Фактор-множество $\Sigma^* / \sim_L$ с операцией конкатенации ($[x][y] = [xy]$) — синтаксический моноид языка L .

Определение 10 (синтаксическая полугруппа). Фактор-множество $\Sigma^+ / \sim_L$ с операцией конкатенации ($[x][y] = [xy]$) — синтаксическая полугруппа языка L .

Для $n \in \mathbb{N}$ примем $\overline{1, n} = \{1, 2, \dots, n\}$.

1.3 Перекрытия

Определение 11 (Язык правильно вложенных слов). Пусть Σ_{call} , Σ_{ret} и Σ_{int} — непесекающиеся алфавиты. Язык правильно вложенных слов $\mathcal{W}$ — это наименьшее множество, которое генерируется следующими конструкторами:

$$\begin{aligned} \varepsilon &\in \mathcal{W} && \text{(пустое слово)} \\ \gamma &\in \mathcal{W} && \text{для каждого } \gamma \in \Sigma_{\text{int}} \quad \text{(внутренний символ)} \\ w_1 \cdot w_2 &\in \mathcal{W} && \text{если } w_1, w_2 \in \mathcal{W} \\ \langle_c w \rangle_r &\in \mathcal{W} && \text{если } w \in \mathcal{W}, \langle_c \in \Sigma_{\text{call}}, \rangle_r \in \Sigma_{\text{ret}} \end{aligned}$$

Выражением будем называть слова языка правильно вложенных слов $\mathcal{W}_{\text{expr}}$, порожденного алфавитами $\Sigma_{\text{call}} = \{(\}\}$, $\Sigma_{\text{ret}} = \{)\}$ и $\Sigma_{\text{int}} = \Delta$, где Δ — счетное множество символов. Абстрактным шаблоном без повторных переменных будем называть слова языка правильно вложенных слов $\mathcal{W}_{\text{pat}}$, порожденного алфавитами $\Sigma_{\text{call}} = \{(\}\}$, $\Sigma_{\text{ret}} = \{)\}$ и $\Sigma_{\text{int}} = \{e, s, t\}$.

Замечание 1. Формальное описание абстрактного шаблона без повторных переменных соответствует таким шаблонам языка Рефал, в которых все переменные имеют различные имена и атомарные символы не встречаются вовсе. Например,

для диалекта Рефал5- λ , поддерживающего безымянные переменные, из абстрактного шаблона можно получить обычный, заменив все символы $e(s, t)$ абстрактного шаблона на символы $e \cdot _ (s \cdot _, t \cdot _)$ шаблона Рефал5- λ .

Введем также понятие шаблона с пронумерованными переменными: каждому шаблону $p \in \mathcal{W}_{\text{pat}}$ поставим в соответствие слово над алфавитом $\Delta_{\mathbb{N}} = \{ (,) \} \cup \{ e, s, t \} \times \mathbb{N}$ такое, что все вхождения символов e, s, t в p в шаблоне с пронумерованными переменными заменяются на буквы из $\{ e, s, t \} \times \mathbb{N}$, причем i -тому вхождению символа e в p соответствует буква (e, i) (обозначим e_i). Аналогично для s и t . Скобки $(,)$ остаются на месте. Для шаблона p будем обозначать соответствующий ему шаблон с пронумерованными переменными $p_{\mathbb{N}}$

Этот формализм нужен лишь затем, чтобы формализовать понятие сопоставления с образцом.

Соответствие переменных множествам их допустимых значений было приведено в обзоре базисного Рефала, теперь же формализуем это соответствие с учетом, что рассматриваются только абстрактные шаблоны без повторных переменных. Будем говорить, что выражение w *допускает сопоставление* с образцом p , если существует строковый морфизм $\phi: \Delta_{\mathbb{N}}^* \rightarrow \mathcal{W}_{\text{expr}}$, действующий следующим образом:

$$\begin{aligned} \phi((s, i)) &\mapsto \gamma \in \Sigma_{\text{int}} \quad \forall i \in \mathbb{N}; \\ \phi((t, i)) &\mapsto \gamma \in \Sigma_{\text{int}} \text{ или } \phi((t, i)) \mapsto (v), \quad v \in \mathcal{W}_{\text{expr}} \quad \forall i \in \mathbb{N}, \end{aligned}$$

при этом $\phi(p_{\mathbb{N}}) = w$.

Определение 12 (Язык шаблона). Языком шаблона $p \in \mathcal{W}_{\text{pat}}$ будем называть множество всех выражений $w \in \mathcal{W}_{\text{expr}}$, которые допускают сопоставление с p . Обозначать это множество будем как $\mathcal{L}(p)$.

Каждая функция Рефала задается последовательностью предложений, каждое из которых в свою очередь содержит шаблон в левой части. Для некоторой функции f , содержащей n предложений, будем обозначать i -тый по счету (считая сверху вниз) шаблон предложения как $f.p_i$. Последовательность всех шаблонов функции $\langle f.p_1, f.p_2, \dots, f.p_n \rangle$ будем обозначать как **pat** f .

Определение 13 (Перекрытие). Будем говорить, что шаблон p *перекрывается* или *экранируется* шаблонами $p_1, p_2, \dots, p_k$, если

$$\mathcal{L}(p) \subseteq \bigcup_{i=1}^k \mathcal{L}(p_i).$$

Будем говорить, что перекрытие (экранирование) *множественное*, если $k > 1$.

Итак, после введения всех необходимых понятий, мы можем перейти к определению задачи распознавания перекрытия:

Определение 14 (Задача распознавания перекрытия). Задача распознавания перекрытия в функции f с n предложениями заключается в том, чтобы для каждого шаблона $p_i \in \mathbf{pat} f$, $i \in \overline{1, n}$ найти минимальное по включению множество $I = \{i_1, i_2, \dots, i_k\} \subseteq \overline{1, i-1}$ такое, что p_i перекрывается шаблонами $f.p_{i_1}, f.p_{i_2}, \dots, f.p_{i_k}$, или показать, что такого множества не существует.

Отметим, что решение задачи распознавания перекрытия неоднозначно, так как для одного и того же шаблона можно найти несколько минимальных по включению множеств индексов таких, что соответствующие им шаблоны перекрывают искомый. Пример такого случая приведён в листинге 2. Предложение 5 перекрывается предложениями 3 и 4, а также предложением 1. При этом множества $\{3, 4\}$ и $\{1\}$ несравнимы по включению.

Листинг 2 — Пример неоднозначного экранирования предложений Рефал-функции

```

1 F {
2     (t._ t._) e._ = ...;           /* 1 */
3     e._ (s._ e._ s._) e._ = ...;   /* 2 */
4     e._ s._ (t._) = ...;           /* 3 */
5     e._ (e._) (t._) = ...;         /* 4 */
6     (t._ t._) t._ (t._) = ...;     /* 5 */
7 }
```

Забегая вперед, отметим, что в текущей постановке задача распознавания перекрытия алгоритмически труднее, чем ее упрощенный вариант:

Определение 15 (Упрощенная задача распознавания перекрытия). Упрощенная задача распознавания перекрытия в функции f заключается в том, чтобы

для каждого шаблона $p_i \in \mathbf{pat} f$ определить, экранируется ли он шаблонами $p_1, p_2, \dots, p_{i-1}$.

Искомое определению задачи распознавания перекрытия будем называть теперь полным или точным.

1.4 Регулярное представления шаблонов

Регулярное представление шаблона представляет особый интерес, поскольку, в сравнении с контекстно-свободными языками (в частности, языками с магазинных автоматов, управляемых входом), коими являются $\mathcal{W}_{\text{expr}}$ и $\mathcal{W}_{\text{pat}}$, регулярные языки более просты для анализа.

1.4.1 Каскадное произведение автоматов

Рассмотрим основную теоретическую конструкцию, позволяющую извлекать регулярное представление шаблонов — каскадное произведение автоматов:

Определение 16 (Каскадное произведение автоматов). Пусть $A_1 = \langle Q_1, \Sigma, \delta_1, q_{0_1}, F_1 \rangle$ и $A_2 = \langle Q_2, \Sigma \times Q_1, \delta_2, q_{0_2}, F_2 \rangle$ — детерминированные конечные автоматы. Каскадным произведением $A_1 \circ A_2$ называется ДКА $\langle Q, \Sigma, \delta, q_0, F \rangle$, где

$$\begin{aligned} Q &= Q_1 \times Q_2, \\ q_0 &= (q_{0_1}, q_{0_2}), \\ F &= F_1 \times F_2, \\ \delta((q_1, q_2), a) &= (\delta_1(q_1, a), \delta_2(q_2, (a, q_1))). \end{aligned}$$

Иногда будем просто говорить о каскаде (двух и более автоматов), подразумевая каскадное произведение автоматов.

Определение, данное выше, является вариантом прямого произведения автоматов. Как и многие другие операции над ДКА, использующие прямое произведение (например, пересечение и объединение), каскадное произведение можно описать как систему из двух автоматов, работающих параллельно на одном и том

же входном слове. В случае каскада двух автоматов между ними проявляется односторонняя зависимость: оба автомата синхронно читают посимвольно входное слово $w \in \Sigma^*$, при этом первый автомат A работает автономно над алфавитом Σ , а второй автомат, помимо символа $w[i]$, использует текущее (до перехода по $w[i]$) состояние первого автомата q , т.е. работает над алфавитом $\Sigma \times Q_1$.

Основная идея заключается в делегировании распознавания вложенных подшаблонов элементам каскада.

Введем искомый алфавит $\Gamma_0 = \{b, s, (,)\}$. b является мета-символом, соответствующим словам $\mathcal{W}_{\text{expr}} \ni w = (v)$, $v \in \mathcal{W}_{\text{expr}}$, s также является мета-символом, соответствующим словам $\mathcal{W}_{\text{expr}} \ni w = \gamma \in \Sigma_{\text{int}}$. Будем рассматривать регулярные выражения r над алфавитом Γ_0 и ДКА A над этим же алфавитом. Будем обозначать множество слов $\{w \mid w \in \Gamma_0^*\}$, принадлежащие языку $r(A)$, как $R(r)$ ($R(r)$). Отклонение от стандартного обозначения через $\mathcal{L}$ сделано во избежании путаницы: каждое слово языка $r(A)$ в силу смысла символов $\gamma \in \Gamma_0$ само задает некоторый язык слов-выражений из $\mathcal{W}_{\text{expr}}$. Для слова $u \in R(r)$ поставим ему в соответствие слово $u_{\mathbb{N}}$ над $\Gamma_{\mathbb{N}} = \{(,)\} \cup \{b, s\} \times \mathbb{N}$ с пронумерованными переменными, аналогично тому, как это было сделано для шаблонов $p \in \mathcal{W}_{\text{pat}}$ и $p_{\mathbb{N}}$. Будем говорить, что w допускает сопоставление с r , если

$$\exists u \in R(r) \exists \phi: \{b, s\} \times \mathbb{N} \rightarrow \mathcal{W}_{\text{expr}} \mid \phi(u_{\mathbb{N}}) = w,$$

при этом

$$\phi((b, i)) \mapsto (w) \in \mathcal{W}_{\text{expr}} \forall i \in \mathbb{N};$$

$$\phi((s, i)) \mapsto \gamma \in \Sigma_{\text{int}} \forall i \in \mathbb{N};$$

Множество слов $w \in \mathcal{W}_{\text{expr}}$, допускающих сопоставление с r , будем обозначать как $\mathcal{L}(r)$. Любой шаблон $p \in \mathcal{W}_{\text{pat}}$ можно представить в виде регулярного выражения r над алфавитом Γ так, что $\mathcal{L}(p) = \mathcal{L}(r)$. Данный факт следует непосредственно из определения самих e, t, s -символов, ниже представлено соответствие между символами и регулярными выражениями:

- e -символ соответствует выражению $(b|s)^*$;
- t -символ соответствует выражению $(b|s)$;
- s -символ соответствует выражению s .

Введем функцию глубины вложенности на элементах языка правильно вложенных слов:

$$d(w, i) = \begin{cases} 0, & i = 0 \\ d(w, i - 1) + 1, & w[i] \in \Sigma_{\text{call}} \\ d(w, i - 1) - 1, & w[i] \in \Sigma_{\text{ret}} \\ d(w, i - 1), & w[i] \in \Sigma_{\text{int}} \end{cases}$$

Тогда максимальным уровнем вложенности некоторого слова w будет

$$\max d(w) = \max_{i \in \overline{1, |w|}} d(w[i]).$$

Подшаблоном p уровня вложенности k (или просто k -подшаблоном) будем называть подслово $w[i : j]$ такое, что

$$d(w, i) = k \wedge d(w, j) = k - 1 \wedge \forall m \in \overline{i + 1, j - 1} \ d(w, m) \geq k - 1.$$

Обозначим множество всех k -подшаблонов p как **subpat** _{k} (p).

Рассмотрим теперь теоретическую конструкцию каскада по данному шаблону p . Сначала для $k = \max(p)$ построим регулярные выражение r_i над алфавитом Γ_0 по правилам, описанным выше, для всех k -подшаблонов p_i ; далее построим соответствующие ДКА A_i .

Рассмотрим ДКА-объединение A всех A_i с размеченными состояниями: каждое финальное состояние f автомата A помечается множеством $\alpha \subset \mathbf{subpat}_k(p)$, если все пути в автомате A до состояния f принадлежат языкам регулярных выражений, соответствующим k -подшаблонам $p_j \in \alpha$. Чтобы автомат корректно работал только с k -шаблонами, автомат A совмещается с автоматом-лифтом на уровень скобочной вложенности k . Начальным состоянием A становится начальное состояние лифта, последний "этаж" лифта совмещается с бывшим начальным состоянием A . Пример автомата-лифта для уровня 2 приведен на рисунке РИС!.

Полученный автомат A является управляющим автоматом каскада. Если $k > 1$, то следующий элемент каскада будет управляться символом входного слова и состоянием A . Для построения управляемого автомата B необходимо рассмотреть множество **subpat** _{$k-1$} , его элементы включают себя k -шаблоны в качестве

подшаблонов. Для принятия решения о переходе по этим k -шаблонам автомат B использует состояния автомата A , аннотации финальных состояний A позволяют автомату B получать необходимую информацию о том, какие шаблоны прочитаны A .

Итак, конструкция выше задает пару автоматов, каскадное произведение которых $A \circ B$ распознает $k - 1$ -шаблоны. Повторяя процедуру выше для $k, k - 1, \dots, 0$ -шаблонов, получаем каскад $A_k \circ A_{k-1} \circ \dots \circ A_0$, распознающий искомый шаблон.

Рассмотрим пример функции, приведённой в листинге 3.

Листинг 3 — Пример функции на базисном Рефале

```

1 f {
2   t (e (s) s) = ...
3   ((t) e s) s = ...
4 }
```

Для примера в листинге 3 шаблонами уровня вложенности 2 будут s, t ; уровня 1 — $e(s)s, (t)es$; без скобочной вложенности — $t(e(s)s), ((t)es)s$.

1.4.2 Переход от каскада к ДКА

1.5 Распознавания перекрытий с помощью ДКА шаблонов

1.6 Иные применения ДКА шаблонов

2 Конструкторская часть

2.1 Общая архитектура программного комплекса

2.1.1 Обработка ошибок

2.2 Архитектура подсистемы семантического анализатора

2.2.1 Вспомогательные подмодули семантического анализатора

2.2.2 Алгоритм приведения шаблонов функции к ДКА

2.3 Алгоритмы извлечения документации к шаблонам функции

2.4 Пользовательский интерфейс

3 Технологическая часть

3.1 Обзор используемых технологий

3.2 Реализация модуля для работы с абстрактными паттернами

3.3 Реализация модуля для работы с автоматами

3.4 Реализация алгоритма обнаружения перекрытий

ЗАКЛЮЧЕНИЕ

СПИСОК ЛИТЕРАТУРЫ